

隱馬可夫模型於 DNA 序列之分析

Hidden Markov Models for Analysis of DNA Sequence Data

組別：C-25 組員：謝承佑、曾曄翔
指導教授：賀保羅教授

簡介 Introduction

本專題旨在透過隱馬可夫模型（Hidden Markov Model, HMM）分析人類 DNA 序列中的統計特徵，特別聚焦於不同區域（例如高 GC 含量與低 GC 含量）在序列生成行為上的差異。研究初期假設 DNA 序列中存在 CG-rich 與 CG-poor 區域，並建立三個隱藏狀態：High、Mid、Low，分別對應不同 GC 含量區域。此外，考量到人類基因組中特有的 Alu 重複序列，加入一個外部決定性狀態 (Alu)，使模型更貼近人類基因的實際分佈特性。

隱馬可夫模型介紹

- 隱馬可夫模型是一種統計模型，常用於處理序列型資料，例如語音、文字、生物序列等。
- 它假設資料的生成是由不可觀察的隱藏狀態（hidden states）所控制，透過觀測值間接推論其變化機制。
- 模型組成：初始機率向量 (A)、狀態轉移機率矩陣 (A)、發射機率矩陣 (B)


系統架構圖與實作流程

Hidden Markov Model System Architecture



- Read Data：讀取訓練與驗證用 DNA 序列
- Estimation：使用 Viterbi 解碼進行初步狀態分配
- Training：使用 Baum-Welch 演算法進行 EM 訓練
- 使用 Forward 計算驗證序列機率
- 與隨機產生序列機率做 Improvement rate 比較

模型圖示



重要演算法

$$\delta_t(i) = \operatorname{argmax}_{1 \leq j \leq N} [v_{t-1}(j) A_j(i)]$$

Viterbi Algorithm

Viterbi 演算法是一種動態規劃方法，用來從觀測序列中推斷出最可能的隱藏狀態路徑。

Forward-Backward Algorithm

$$P_{t+1}(j) = [\sum_{k=1}^N P_t(j) A_{jk}] B_k(o_{t+1})$$


Forward-Backward 是一種基於全機率公式的演算法，計算序列中每一時刻屬於每個隱藏狀態的機率。

Baum-Welch Algorithm

$$E - Step: L(\lambda, \lambda') = \sum_H P(H|O, \lambda') \log P(O, H|\lambda)$$
$$M - Step: \lambda' = \operatorname{argmax}_{\lambda} \sum_H P(H|O, \lambda') \log P(O, H|\lambda)$$

Baum-Welch 演算法是 HMM 的標準訓練方法，屬於 EM (Expectation-Maximization) 的一種。

實驗成果分析



- 資料來源：取自 NCBI RefSeq 資料庫，使用人類基因組第六條染色體 (Homo sapiens chromosome 6) 的標準參考序列。
- 成果比較：與 0/1/2 階馬可夫模型對比，以評估模型的優化效果
- 實驗成果：本模型在多數資料上展現介於一階至二階模型之間的效能，在部分資料上表現優於二階馬可夫模型

過程中遇到的困難&解決方法

- 模型學不到明顯的狀態結構：調整隱狀態設計並結合外部標註以強化結構差異。
- EM 容易陷入局部最小值：嘗試不同初始狀態作為起始參數，提高收斂結果品質。
- 模型容易過擬合 (Overfitting)：更改隱狀態數量、EM 多次初始化
- 數值精度問題 (機率過小)：使用 log-domain 計算並用字串表示

結論

本研究結果顯示，當測試序列中具有明顯的 CG-rich (CG 高) 與 CG-poor (CG 低) 區域差異時，隱馬可夫模型 (HMM) 在序列生成與區段辨識上的預測能力顯著提升。

此外，若資料中包含 Alu 重複序列 (尤其為真實的轉錄重複片段)，模型所產生的機率明顯高於隨機模型與低階馬可夫模型。這些結果說明，CG 結構與重複序列資訊是影響 HMM 效能的關鍵因素，未來可作為辨識具功能性區域的重要依據，並應用於基因註解、序列分類等生物資訊任務。